

Identifikasi Pelat Nomor Kendaraan Dalam Kondisi Kurang Cahaya Menggunakan Metode YOLOv7 dan OCR

Tugas Akhir

diajukan untuk memenuhi salah satu syarat

memperoleh gelar sarjana

dari Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

1301194330

Muhammad Mirza Rizkiawan



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2023

LEMBAR PENGESAHAN

**Identifikasi Pelat Nomor Kendaraan Dalam Kondisi
Kurang Cahaya Menggunakan Metode YOLOv7 dan OCR**

**Identification of vehicle license plates in lowlight conditions using
YOLOv7 and OCR methods**

NIM : 1301194330

Muhammad Mirza Rizkiawan

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat memperoleh
gelar pada Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung, 05 Juli 2023

Menyetujui

Pembimbing I,

Pembimbing II,

Bedy Purnama, S.Si., M.T., Ph.D

Dr. Gamma Kosala, S.Si.

NIP: 10790050

NIP: 21920013

Ketua Program Studi
Sarjana Informatika,

Dr. Erwin Budi Setiawan, S.Si., M.T.
NIP: 00760045

LEMBAR PERNYATAAN

Dengan ini saya, Muhammad Mirza Rizkiawan menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul **“Identifikasi Pelat Nomor Kendaraan Dalam Kondisi Kurang Cahaya Menggunakan Metode YOLOv7 dan OCR”** beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam buku TA atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 05 Juli 2023

Yang Menyatakan

Muhammad Mirza Rizkiawan

Identifikasi Pelat Nomor Kendaraan Dalam Kondisi Kurang Cahaya Menggunakan Metode YOLOv7 dan OCR

Muhammad Mirza Rizkiawan¹, Bedy Purnama, S.Si., M.T., Ph.D², Dr. Gamma Kosala, S.Si.³

^{1,2,3}Fakultas Informatika, Universitas Telkom, Bandung

¹mirzarizkiawan@students.telkomuniversity.ac.id, ²bedypurnama@telkomuniversity.ac.id,

³gammakosala@telkomuniversity.ac.id

Abstrak

Pelat nomor kendaraan adalah bagian penting dari registrasi dan identifikasi kendaraan bermotor, yang menyimpan informasi terkait kendaraan dan pemiliknya. Saat ini, Electronic Traffic Law Enforcement (ETLE) menggunakan sistem Automatic Licence Plate Recognition (ALPR) untuk mendeteksi pelanggaran lalu lintas. Namun, penerapan ALPR dalam kondisi kurang cahaya masih menjadi tantangan. Oleh karena itu, diperlukan solusi berbasis computer vision untuk membangun sistem ALPR yang dapat berfungsi secara optimal dalam kondisi kurang cahaya. Penelitian ini bertujuan untuk mengembangkan sistem ALPR yang dapat beroperasi dengan baik dalam kondisi kurang cahaya. Dalam penelitian ini, digunakan model YOLOv7, sebuah varian populer dari YOLO yang memiliki kecepatan tinggi dan akurasi tinggi dalam deteksi objek real-time. Melalui berbagai skenario percobaan, model yang diusulkan dalam penelitian ini mencapai presisi sebesar 98.1%, recall sebesar 95.5%, dan mAP@0.5 sebesar 99.3% untuk kelas Pelat Nomor. Penelitian ini mengimplementasikan tiga model OCR yaitu easyocr dengan akurasi 35.6%, kerasocr dengan akurasi 52.5% dan pytesseract dengan akurasi 19.7%.

Kata kunci : Deteksi Objek, Automatic License Plate Recognition, YOLOv7, OCR

Abstract

Vehicle license plates are an essential part of motor vehicle registration and identification, storing information related to the vehicle and its owner. Currently, Electronic Traffic Law Enforcement (ETLE) employs the Automatic License Plate Recognition (ALPR) system to detect traffic violations. However, implementing ALPR in low-light conditions remains a challenge. Therefore, a computer vision-based solution is needed to build an ALPR system that can function optimally in low-light conditions. This research aims to develop an ALPR system that can perform well in low-light conditions. The YOLOv7 model, a popular variant of YOLO known for its high speed and accuracy in real-time object detection, is utilized in this study. Through various experimental scenarios, the proposed model achieves a precision of 98.1%, a recall of 95.5%, and mAP@0.5 of 99.3% for the License Plate class. The research also implements three OCR models: easyocr with an accuracy of 35.6%, kerasocr with an accuracy of 52.5%, and pytesseract with an accuracy of 19.7%.

Keywords: Object Detection, Automatic License Plate Recognition, YOLOv7, OCR

1. Pendahuluan

Latar Belakang

Pelat nomor kendaraan bermotor atau tanda nomor kendaraan bermotor (TNKB) adalah salah satu bagian dari registrasi dan identifikasi kendaraan bermotor, melalui undang-undang nomor 22 tahun 2009 tentang lalu lintas dan angkutan jalan (LLAJ) setiap kendaraan bermotor yang dioperasikan di jalan wajib dilengkapi dengan Surat Tanda Kendaraan Bermotor (STNK) dan Tanda Nomor Kendaraan Bermotor (TNKB). Pelat nomor kendaraan memuat informasi yang berkaitan dengan kendaraan dan pemilik kendaraan, sehingga identitas dari pemilik kendaraan dapat dilacak melalui pelat nomor kendaraan. Saat ini, Ditlantas Polda Metro Jaya menggunakan teknologi *Electronic Traffic Law Enforcement* (ETLE) untuk mencatat pelanggaran – pelanggaran dalam berlalu lintas serta mendeteksi pelat nomor kendaraan sebagai identifikasi pemilik kendaraan yang melakukan pelanggaran.

Salah satu sistem yang umum digunakan untuk melakukan identifikasi pelat nomor kendaraan adalah *Automatic Licence Plate Recognition* (ALPR). Biasanya sistem ALPR memiliki tiga tahapan: deteksi pelat nomor, segmentasi karakter dan rekognisi karakter [1]. Untuk melanjutkan ke tahap berikutnya sistem ALPR perlu mendeteksi pelat nomor kendaraan dengan akurasi yang tinggi, jika akurasi deteksi pelat nomor kendaraan rendah maka akan mengakibatkan akurasi pada tahapan berikutnya menjadi rendah. Permasalahan berikutnya, jika sistem ALPR tidak dapat mendeteksi pelat nomor kendaraan maka sistem ALPR tidak dapat dilanjutkan ke tahapan berikutnya. Untuk melakukan deteksi pelat nomor kendaraan, pencahayaan gambar juga perlu

diperhatikan. Proses deteksi pelat nomor kendaraan akan lebih sulit dilakukan dalam kondisi kurang pencahayaan karena kurangnya pantulan cahaya serta banyaknya area gelap dan *noise* pada gambar [2].

Topik dan Batasannya

Topik yang dibahas pada penelitian ini adalah pendeteksian pelat nomor kendaraan dalam kondisi kurang Cahaya, yang dimaksud kondisi kurang cahaya dalam penelitian ini adalah kondisi pada malam hari sekitar pukul 18.00 hingga 21.00. Batasan pada penelitian ini yaitu *dataset* yang digunakan merupakan citra pelat nomor kendaraan dalam kondisi kurang cahaya dan hanya menggunakan pelat nomor kendaraan di Indonesia.

Tujuan

Berdasarkan penjelasan pada rumusan masalah, tujuan dari penelitian ini yaitu mengimplementasikan metode YOLOv7 dan OCR untuk mengidentifikasi pelat nomor kendaraan dalam kondisi kurang cahaya dan meningkatkan performa deteksi objek berupa pelat nomor kendaraan pada kondisi kurang Cahaya menggunakan metode YOLOv7 dan OCR.

Organisasi Tulisan

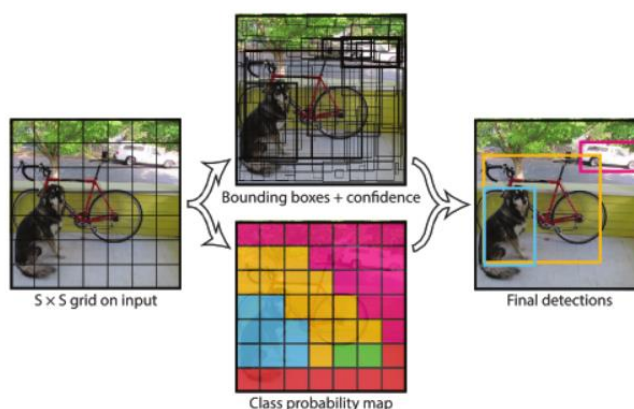
Jurnal Tugas Akhir ini terdiri dari 5 bagian, yaitu Bab 1 yang terdiri dari pendahuluan dan penjelasan latar belakang, Bab 2 yang memuat penjelasan studi terkait, Bab 3 memuat penjelasan rancangan sistem dan metode penelitian, Bab 4 yang terdiri dari hasil pengujian dan analisis hasil pengujian, dan Bab 5 memuat kesimpulan dan penelitian yang telah dilakukan.

2. Studi Terkait

2.1 You Only Look Once (YOLO)

Model YOLO (You Only Look Once) adalah serangkaian model deteksi objek yang terkenal digunakan untuk deteksi dan klasifikasi objek secara waktu nyata dalam visi komputer [3]. YOLO adalah algoritma yang dapat secara *real-time* mendeteksi dan mengenali berbagai objek dalam suatu gambar. YOLO menggunakan *convolutional neural network* (CNN) untuk mendeteksi objek secara waktu nyata dan hanya memerlukan satu kali propagasi maju melalui *neural network* untuk mendeteksi objek.

Sistem YOLO membagi gambar input menjadi kisi $S \times S$. Jika pusat objek jatuh ke dalam sel kisi, sel kisi tersebut bertanggung jawab untuk mendeteksi objek tersebut [4]. Setiap sel kisi memprediksi kotak pembatas B dan skor kepercayaan diri untuk kotak tersebut. Skor kepercayaan ini mencerminkan seberapa yakin model bahwa kotak itu berisi objek dan juga seberapa akurat menurut prediksi kotak itu. Setiap kotak pembatas terdiri dari 5 prediksi: x , y , w , h , dan *confidence score*. Koordinat (x ; y) mewakili pusat kotak relatif terhadap batas sel kisi. Lebar dan tinggi diperkirakan relatif terhadap keseluruhan gambar. Terakhir, prediksi keyakinan merepresentasikan IOU antara kotak prediksi dan kotak kebenaran dasar mana pun [3]. Contoh dari metode algoritma YOLO dapat dilihat pada Gambar 1.



Gambar 1. Algoritma Metode YOLO [3]

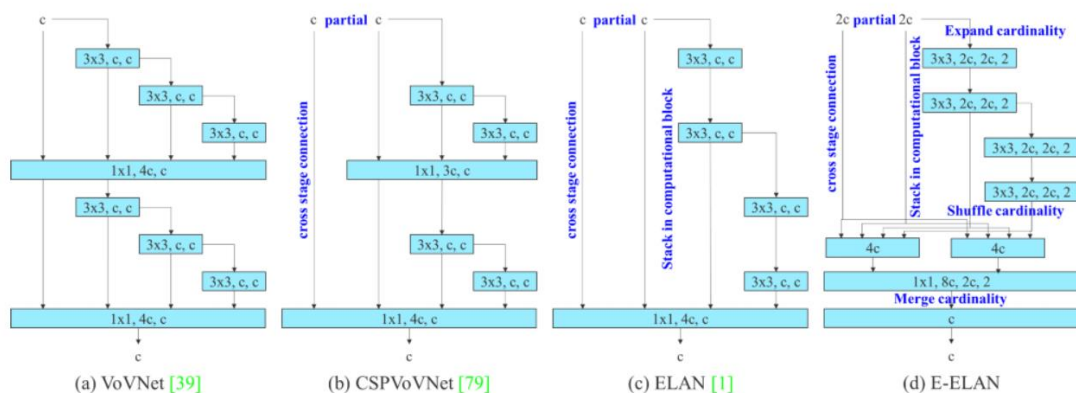
YOLOv1 memperkenalkan pendekatan deteksi target berbasis grid, menggunakan posisi titik pusat target di dalam grid untuk meningkatkan kecepatan deteksi secara signifikan. YOLOv2 mengadopsi peta fitur multi-skala dan menggabungkannya melalui lapisan melewati untuk mencapai deteksi multi-skala berdasarkan SSD. YOLOv3 memperdalam struktur jaringan dengan model residual dan menggunakan arsitektur FPN untuk deteksi

multi-skala. YOLOv4 menambahkan CSP ke blok residu besar Darknet53, mengurangi perhitungan dan meningkatkan akurasi melalui hierarki lintas tahap. Dalam perbandingan dengan YOLOv4, YOLOv5 memberikan tingkat akurasi yang lebih tinggi dan kemampuan yang lebih baik dalam mengenali objek kecil. YOLOv5 lebih fleksibel, lebih cepat, dan sangat cocok untuk penerapan model yang cepat [5].


2.2 YOLOv7

YOLOv7 adalah model deteksi objek *real-time* yang dilatih hanya pada kumpulan data MS COCO tanpa menggunakan *backbone* yang telah dilatih sebelumnya. YOLOv7 adalah versi yang ditingkatkan dari model YOLOv5 dan memiliki beberapa fitur yang membuatnya efisien dan akurat. YOLOv7 mengungguli semua pendeteksi objek yang dikenal dalam hal kecepatan dan akurasi dalam kisaran dari 5 FPS hingga 160 FPS dan memiliki akurasi tertinggi 56,8% AP di antara semua pendeteksi objek *real-time* yang dikenal dengan 30 FPS atau lebih tinggi pada GPU V100. YOLOv7 menjadi *state-of-the-art* untuk *real-time object detector* dengan mengurangi 40% parameter dan 50% komputasi secara efektif, dan memiliki kecepatan inferensi yang lebih cepat dan akurasi deteksi yang lebih tinggi [6].

Terdapat tiga fitur utama yang digunakan dalam arsitektur YOLOv7 yaitu: *E-Elan layer aggregation network*, *Model scaling for varying sizes*, dan *Trainable bag-of-freebies*. Modul *Extended ELAN (E-ELAN)* dapat digunakan untuk membuat berbagai macam arsitektur jaringan yang berbeda, E-ELAN menggunakan kardinalitas *expand*, *shuffle* dan *merge* untuk mencapai kemampuan untuk terus meningkatkan kemampuan belajar jaringan tanpa merusak jalur gradien asli. Tujuan utama model scaling adalah untuk menyesuaikan beberapa atribut model dan menghasilkan model dengan skala yang berbeda untuk memenuhi kebutuhan kecepatan inferensi yang berbeda. BoF atau Bag of Freebies adalah metode yang meningkatkan performa model tanpa menambahkan training cost. Dalam implementasinya YOLOv7 memperkenalkan BoF berikut: *Planned Re-parameterized Convolution*, *Coarse for Auxiliary and Fine for Lead Loss*, dan *Lead Head Guided Label Assigner and Coarse-to-Fine Lead Head Guided Label Assigner* [6]. Arsitektur E-ELAN pada YOLOv7 dapat dilihat pada Gambar 2 dan arsitektur model scaling pada YOLOv7 dapat dilihat pada gambar 3.



Gambar 2. Arsitektur E-ELAN pada YOLOv7 [6]



Gambar 3. Model Scaling pada YOLOv7 [6]

2.3 Automatic License Plate Recognition (ALPR)

Automatic Licence Plate Recognition (ALPR) adalah proses identifikasi pelat nomor kendaraan dan rekognisi nomor kendaraan untuk berbagai proses seperti rekaman kendaraan yang datang, penjadwalan, manajemen trafik, kontrol keamanan di daerah terlarang, jalan tol, deteksi kecepatan kendaraan, dan lainnya [7].

Dalam penelitian lain [8], ALPR adalah teknologi yang secara otomatis mengenali karakter pada pelat nomor kendaraan dalam sebuah citra.

Sistem ALPR yang sudah ada dapat dibagi menjadi dua kategori yaitu *multistage* dan *single-stage methods*. Sebagian besar solusi ALPR yang sudah ada dapat dipertimbangkan sebagai *multi-stage method* yang terdiri dari tiga tahap yaitu deteksi pelat kendaraan, segmentasi karakter dan rekognisi karakter [7].

Terdapat banyak penelitian terkait deteksi pelat nomor kendaraan, segmentasi karakter dan rekognisi karakter dari berbagai sudut pandang dan berbagai tantangan [9]. Meskipun banyak penelitian telah diusulkan selama beberapa tahun terakhir, sampai sekarang terdapat berbagai tantangan untuk melakukan deteksi pelat nomor kendaraan pada situasi terbuka seperti *blur* pada citra yang digunakan, pengambilan sudut yang berbeda, perbedaan aspek rasio pada setiap negara dsb. Secara keseluruhan deteksi pelat nomor kendaraan dapat di klasifikasikan menjadi empat kategori pendekatan yaitu: karakter, tekstur, warna, dan tepi [7], [9].

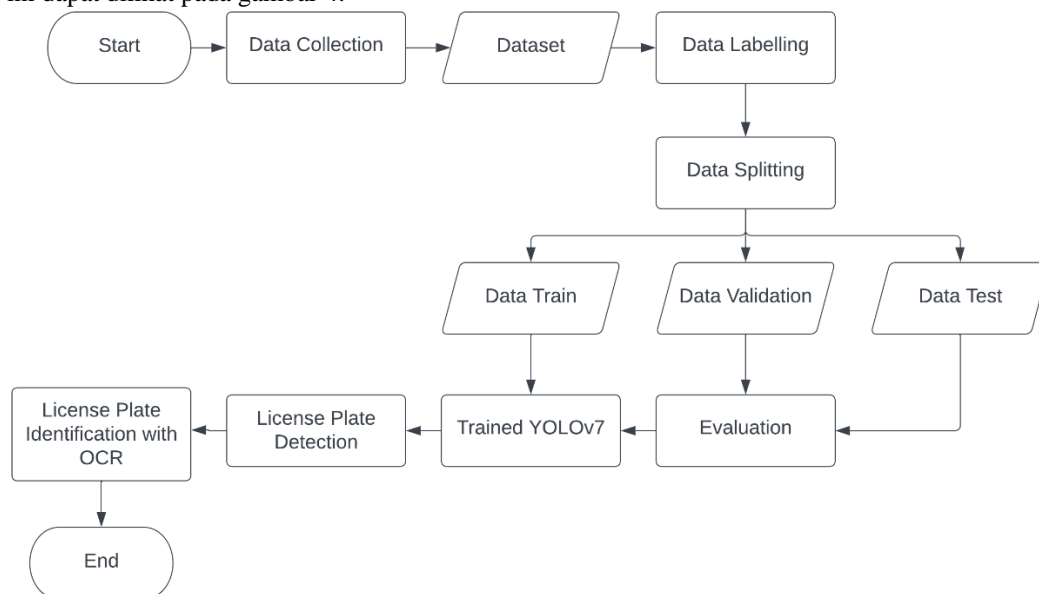
2.4 Optical Character Recognition (OCR)

Optical Character Recognition (OCR) adalah teknik yang digunakan untuk melakukan konversi teks cetak menjadi teks yang dapat diubah. Dengan menggunakan OCR, akurasi dari teks dapat diukur [10]. OCR menerapkan penerjemahan mekanikal atau elektronik tanpa perbedaan terhadap fotografi, karakter tulis tangan atau karakter ketik. OCR terdiri dari berbagai tahapan berbeda seperti *digitization*, *preprocessing*, *segmentation* dan *feature extraction* [11].

Dalam penelitiannya, Sarika dkk [11]. Menyebutkan beberapa implementasi dari OCR, diantaranya translasi suara, aplikasi perbankan, dan digitalisasi perpustakaan. Untuk kasus identifikasi pelat nomor kendaraan, Samantary dkk [12] menggunakan *Tesseract OCR* untuk melakukan lokalisasi pelat kendaraan dengan akurasi 93.34%, kemudian melakukan rekognisi karakter dengan akurasi 91.67%. Dalam penelitian lainnya Singh dkk [13] menggunakan model *Faster RCNN* untuk deteksi pelat nomor kendaraan kemudian menggunakan *LSTM RNN OCR* untuk melakukan segmentasi dan rekognisi teks pada pelat nomor kendaraan. Model ini menghasilkan akurasi 99% untuk deteksi pelat nomor kendaraan dan dapat mengenali 95% data uji dengan benar.

3. Sistem yang Dibangun

Pada penelitian ini sistem yang dibangun untuk melakukan identifikasi pelat nomor kendaraan dalam kondisi kurang cahaya menggunakan metode YOLO untuk melakukan lokalisasi pelat nomor kendaraan pada citra pelat nomor kendaraan dalam kondisi kurang cahaya, kemudian menggunakan OCR untuk melakukan segmentasi dan rekognisi karakter pada pelat nomor kendaraan. Gambaran umum sistem yang di rancang pada penelitian ini dapat dilihat pada gambar 4.



Gambar 4. Rancangan Sistem

3.1 Dataset

Dataset yang digunakan dalam penelitian ini berupa citra pelat nomor kendaraan dalam kondisi kurang cahaya yang dikumpulkan secara langsung menggunakan kamera DSLR. Yang dimaksud kondisi kurang cahaya dalam penelitian ini adalah kondisi sekitar pelat nomor kendaraan yang gelap namun pelat nomor kendaraan masih dapat terlihat seperti kondisi jalan raya pada malam hari. Dataset yang digunakan terdiri dari 960 citra yang kemudian dibagi dengan rasio 80% data latih : 10% data validasi dan 10% data uji. Dataset yang ada kemudian dilakukan proses pelabelan dan anotasi sesuai format yang digunakan YOLOv7, dalam hal ini hanya terdapat satu kelas yaitu pelat nomor atau *license plate*. Tabel 1 menunjukkan jumlah dataset yang digunakan dalam penelitian ini.

Tabel 1. Dataset	
Data	Jumlah Citra
<i>Training</i>	768
<i>Validation</i>	96
<i>Testing</i>	96



Gambar 5. Sample Dataset

Pada gambar 5 dapat dilihat dataset yang digunakan untuk proses training. Dataset yang digunakan merupakan citra kendaraan dalam kondisi kurang pencahayaan. Dataset ini hanya memiliki satu kelas yaitu *license plate*. Sedangkan sampel data uji dapat dilihat pada gambar 6.



Gambar 6. Sampel Data Uji

3.2 Training

Training merupakan langkah dimana data-data dilatih dengan menggunakan model YOLOv7, yang menghasilkan bobot-bobot baru yang akan digunakan dalam proses deteksi pelat nomor kendaraan untuk mendeteksi objek. Hasil dari proses ini adalah terbentuknya model yang telah melalui proses pelatihan dengan menggunakan model YOLOv7, sehingga dapat mengestimasi lokasi pelat nomor kendaraan pada citra-citra yang digunakan dalam pengujian.

3.3 Testing

Testing merupakan langkah dimana model yang telah dilatih menggunakan data latih dapat bekerja dengan baik pada hasil citra uji yang akan dievaluasi. Data uji hanya akan memiliki satu kelas yaitu *license plate*.

3.4 Evaluasi

Untuk mengukur performansi dari sistem yang dibangun diperlukan beberapa kriteria evaluasi. Beberapa variabel dari kriteria evaluasi tersebut dapat dilihat pada Tabel 2.

Tabel 2. Confusion Matrix

	Actual Positive Class	True Negative Class
Predicted Positive Class	True Positive (TP)	False Negative (FN)
Predicted Negative Class	False Positive (FP)	True Negative (TN)

Metrik evaluasi yang digunakan diantaranya:

a. Intersection over Union (IoU)

IoU adalah pengukuran berdasarkan *Jaccard Index*, sebuah koefisien dari kemiripan dua himpunan data. Dalam lingkup deteksi objek IoU mengukur daerah tumpang tindih antara prediksi *bounding box* (B_p) dan *ground-truth bounding box* (B_{gt}) dibagi dengan area gabungan diantara keduanya [14]. IoU dapat dihitung dengan persamaan (1).

$$J(B_p, B_{gt}) = IOU = \frac{\text{area}(B_p \cap B_{gt})}{\text{area}(B_p \cup B_{gt})} \quad (1)$$

b. Precision dan recall

Precision merupakan deteksi benar terhadap semua deteksi oleh model dan *recall* merupakan deteksi benar dari semua *ground-truth*. *Tradeoff* antara *precision* dan *recall* umumnya ditampilkan dalam model. Ketika FP rendah, *precision* akan tinggi, sebagai hasilnya, FN akan bernilai tinggi, menghasilkan nilai *recall* yang rendah. Sebuah detektor dapat dianggap baik jika memiliki nilai *precision* dan *recall* yang tinggi [15]. *Precision* dapat diukur dengan persamaan (2) dan *recall* diukur dengan persamaan (3).

$$P = \frac{\text{correct positives}}{\text{all detection}} = \frac{TP}{TP+FP} \quad (2)$$

$$R = \frac{\text{correct positives}}{\text{all ground truths}} = \frac{TP}{TP+FN} \quad (3)$$

c. Mean Average Precision (mAP)

Mean Average Precision (mAP) adalah rata-rata dari seluruh kalkulasi *average precision* dari berbagai kelas. MAP adalah metrik performansi paling populer dan dapat dihitung dengan persamaan 4.

$$mAP = \frac{1}{C} \sum_{x=1}^C AP_x \quad (4)$$

AP_x adalah *average precision* dari sebagian kelas x , dan C adalah jumlah total dari kelas [15].

4. Evaluasi

4.1 Hasil *Training* Model YOLOv7

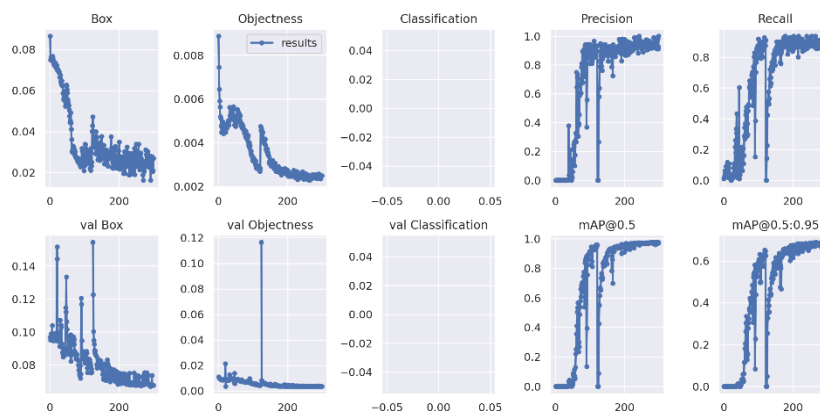
Pada tahap ini, dilakukan training pada model YOLOv7 pada *google colab* dengan menggunakan data latih sebanyak 768 citra kendaraan dalam kondisi kurang cahaya yang telah diberi anotasi *bounding box* pada pelat nomor kendaraan. Dari hasil training ini diharapkan model YOLOv7 mampu mendeteksi keberadaan dan letak pelat nomor kendaraan pada citra dengan kondisi kurang cahaya. Pada penelitian ini dilakukan tiga skenario training model YOLOv7 dengan mengubah beberapa parameter untuk memperoleh model yang optimal. Berikut adalah hasil dari tiga skenario training model YOLOv7:

4.1.1 Skenario *training* pertama

Perintah dan parameter yang digunakan dalam skenario pertama sebagai berikut:

```
python train.py --workers 8 --device 0 --batch-size 32 --data data/coco.yaml --img 416 --cfg
cfg/training/yolov7.yaml --weights " --name yolov7 --hyp data/hyp.scratch.p5.yaml.
```

Dalam skenario ini, *training* dilakukan dengan melibatkan 8 *workers* dan 0 *device*, dengan *batch-size* 32 dan menggunakan pengaturan yang terdapat dalam file *yolov7.yaml*. Proses ini menggunakan gambar input dengan dimensi 416x416 dan tidak melibatkan penggunaan bobot apapun. Hasil dari skenario training pertama dapat dilihat pada gambar 10.



Gambar 7. Hasil *training* skenario pertama

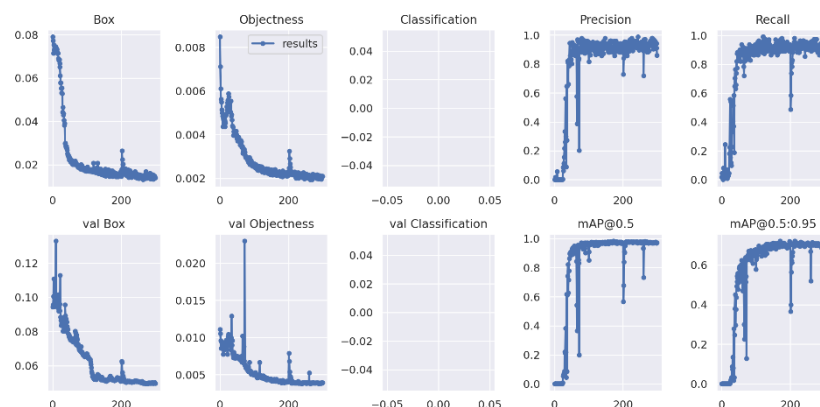
Dari hasil *training* yolov7 pada gambar 7, dapat diamati bahwa nilai precision dan recall model mengalami peningkatan yang stabil hingga mencapai epoch 120. Setelah itu, terjadi penurunan nilai hingga mencapai 0, namun kemudian kembali meningkat dalam rentang 0.7 hingga 0.9. Fenomena ini bisa disebabkan oleh beberapa faktor seperti *overfitting*, ketidakseimbangan jumlah *dataset*, dan konfigurasi parameter yang kurang sesuai. Untuk mengatasi masalah ini, dilakukan skenario pelatihan kedua dengan melakukan perubahan pada beberapa parameter dengan harapan mendapatkan model yang lebih optimal.

4.1.2 Skenario *training* kedua

Perintah dan parameter yang digunakan dalam skenario kedua sebagai berikut:

```
python train.py --workers 8 --device 0 --batch-size 16 --data data/coco.yaml --img 416 --cfg
cfg/training/yolov7.yaml --weights " --name yolov7_train_2 --hyp data/hyp.scratch.p5.yaml
```

Dalam skenario ini, *training* dilakukan dengan parameter yang mirip dengan skenario pertama, hanya parameter *batch-size* yang diubah menjadi 16. Hal ini dilakukan agar memberikan variasi yang lebih besar dalam contoh yang diproses pada setiap iterasi, sehingga model memiliki kesempatan untuk mempelajari pola yang lebih halus dan spesifik.



Gambar 8. Hasil *training* skenario kedua

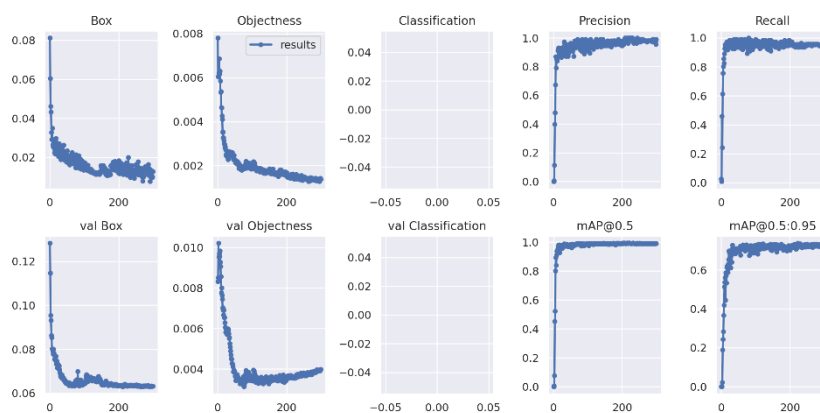
Dari hasil *training* yolov7 pada gambar 8, dapat diamati bahwa nilai *precision*, *recall* dan *mAP* masih mengalami beberapa kali penurunan nilai ditengah proses *training*. Namun penurunan nilai berbeda dengan skenario pertama, nilai *precision*, *recall* dan *mAP* mengalami penurunan beberapa kali tetapi tidak mencapai nilai 0, seperti yang dibahas pada skenario pertama fenomena ini dapat disebabkan oleh beberapa faktor seperti *overfitting*, ketidakseimbangan jumlah *dataset*, dan konfigurasi parameter yang kurang sesuai. Untuk mengatasi masalah ini, dilakukan skenario pelatihan ketiga dengan melakukan perubahan pada beberapa parameter dengan harapan mendapatkan model yang lebih optimal.

4.1.3 Skenario *training* ketiga

Perintah dan parameter yang digunakan dalam skenario kedua sebagai berikut:

```
python train.py --workers 8 --device 0 --batch-size 16 --data data/coco.yaml --img 416 --cfg
cfg/training/yolov7.yaml --weights yolov7.pt --name yolov7_train_3 --hyp data/hyp.scratch.p5.yaml
```

Dalam skenario ini, *training* dilakukan dengan parameter yang mirip dengan skenario kedua, hanya saja terdapat penambahan penggunaan bobot dari yolov7 yang diharapkan dapat membantu proses pelatihan model yolov7.



Gambar 9. Hasil *training* skenario ketiga

Dari hasil *training* YOLOv7 pada gambar 9, dapat diamati bahwa nilai presisi, recall, dan mAP meningkat secara signifikan pada awal proses pelatihan, kemudian stabil sekitar 0.8 hingga 0.9. Ini merupakan hasil yang sangat baik dan lebih optimal dibandingkan dengan skenario pelatihan sebelumnya. Oleh karena itu, bobot yang dihasilkan dari pelatihan dalam skenario ketiga ini digunakan untuk mendeteksi posisi plat nomor kendaraan pada data uji. Setelah itu, dilakukan cropping pada gambar untuk mengisolasi plat nomor, dan kemudian dapat dilakukan identifikasi plat nomor menggunakan OCR (Optical Character Recognition).

4.2 Hasil pengujian Model YOLOv7

Pada tahap ini, dilakukan pengujian terhadap model YOLOv7 yang telah dilatih sebelumnya untuk mengenali letak pelat nomor kendaraan dalam sebuah citra. Pengujian terhadap model YOLOv7 dilakukan dengan melakukan deteksi terhadap data uji dan melihat apakah model YOLOv7 yang telah dilatih dapat mendeteksi lokasi pelat nomor kendaraan dengan baik pada citra dengan kondisi kurang cahaya, contoh hasil deteksi model YOLOv7 dapat dilihat pada gambar 10.



Gambar 10. Hasil deteksi YOLOv7

Berdasarkan hasil analisis pada gambar 10, dapat disimpulkan bahwa model YOLOv7 yang telah melalui proses *training* dengan menggunakan dataset yang digunakan, mampu mengidentifikasi lokasi pelat nomor kendaraan pada gambar dengan kondisi kurang cahaya dengan hasil yang baik. Model ini memiliki confidence score yang berkisar antara 79% hingga 97%. Namun dalam pengujian ini, terdapat beberapa hasil deteksi yang salah, contoh hasil deteksi yang salah dapat dilihat pada gambar 11.

**Gambar 11. Hasil kesalahan deteksi**

Pada gambar 11. Dapat dilihat bahwa sebagian besar kesalahan deteksi pada model YOLOv7 berupa teks lainnya diluar pelat nomor kendaraan pada citra, hal ini dapat disebabkan adanya *overfitting* sehingga model mendeteksi beberapa teks selain pelat nomor kendaraan yang memiliki struktur dan ukuran yang mirip dengan pelat nomor kendaraan. Nilai metrik pengujian secara keseluruhan dapat dilihat pada tabel 3.

Tabel 3. Nilai metrik evaluasi pengujian YOLOv7

Class	Images	Labels	Precision	Recall	mAP@.5	mAP@.5:.95
all	96	111	98.1%	95.5%	99.3%	73.7%

Berdasarkan analisis pada tabel 3, model YOLOv7 yang telah melalui proses pelatihan dengan menggunakan dataset yang digunakan menunjukkan hasil evaluasi yang baik. Model ini memiliki nilai precision sebesar 98.1%, menunjukkan sedikit kesalahan dalam mengklasifikasikan pelat nomor kendaraan dengan jumlah false positive yang rendah. Selain itu, nilai recall sebesar 95.5% menunjukkan kemampuan model dalam mengidentifikasi sebagian besar pelat nomor pada gambar dengan jumlah false negative yang relatif rendah.

Lebih lanjut, nilai mAP@.5 sebesar 99.3% menunjukkan tingkat akurasi yang tinggi dalam mengenali pelat nomor kendaraan dengan overlap minimal sebesar 50%. Namun, nilai mAP@.5:.95 sebesar 73.7% menggambarkan tingkat akurasi yang lebih rendah dalam mengenali pelat nomor dengan overlap antara 50% hingga 95%. Hal ini mengindikasikan bahwa model mampu mengenali dengan baik objek pelat nomor kendaraan yang memiliki overlap yang signifikan, tetapi performanya menurun ketika terdapat objek yang tumpang tindih secara lebih lemah.

4.3. Hasil pengujian *Optical Character Recognition* (OCR)

Dalam penelitian ini, pengujian OCR dilakukan dengan menggunakan hasil deteksi model YOLOv7 terhadap data uji yang telah dilakukan *cropping* pada area yang dianggap bagian dari pelat nomor kendaraan. Hasil *cropping* yang di dapatkan kemudian dibagi berdasarkan warna latar dari pelat nomor kendaraan menjadi pelat nomor kendaraan dengan latar hitam dan pelat nomor kendaraan dengan latar putih. Contoh citra input untuk model OCR dapat dilihat pada gambar 12.



Gambar 12. Citra input model OCR

Identifikasi pelat nomor dilakukan menggunakan tiga model OCR yaitu *easyocr*, *kerasocr*, dan *pytesseract*. Evaluasi dilakukan dengan memperoleh akurasi, di mana hasil deteksi teks dari model OCR dibandingkan dengan *ground truth* yang dapat ditemukan pada pelat nomor menggunakan teknik *string matching*. Contoh hasil pengujian pada pelat nomor dengan latar hitam dapat dilihat pada tabel 4. Dan contoh hasil pengujian pada pelat nomor dengan latar putih dapat dilihat pada tabel 5.

Tabel 4. Hasil pengujian pelat nomor warna hitam

actual license plate	OCR Methods		
	Easyocr	kerasocr	pytesseract
B 2897 SIA	b 2897 sia	b 2897 sia	
B 1366 RFJ	b 7366 rfj	b 1366 rfj ta	b13 1366 rfi
B 1456 SZM	b	b 1456 szm osnn	
E 1431 VE	e	e 1431 ve 03125	e 1431 ve
B 1034 PYT	b	b 103 pyt 0626	per pry
B 1654 WKU	B	b 164 wku 2121	b 1654 wku
B 1815 TJU	B	tju 1815 b onz	b 1819
B 2197 SJH	B	sjh 2157 b	b 2131 sjh
B 2990 BID	B	bidi 2690 b o7 2zl	} 2990, bid
B 8699 HX	B	hx 8699 b 25 05	

Tabel 4 menunjukkan hasil pengujian pada pelat nomor dengan latar hitam. Hasil pengujian menunjukkan model *easyocr* dapat melakukan identifikasi huruf dan angka pada pelat nomor kendaraan dengan latar hitam, namun sebagian besar hasil deteksi hanya menunjukkan huruf awal dari pelat nomor kendaraan. Hasil pengujian pada model *kerasocr* menunjukkan hasil yang cukup baik dengan mendeteksi huruf dan angka pada pelat nomor kendaraan secara lengkap namun dalam beberapa pengujian terdapat angka dan huruf diluar pelat nomor kendaraan yang dapat berasal dari masa berlaku pelat nomor kendaraan atau angka dan huruf lainnya pada citra pelat nomor kendaraan, pada beberapa pengujian juga terhadap kesalahan dalam urutan identifikasi huruf pada pelat nomor kendaraan. Model *pytesseract* menunjukkan hasil yang mendekati urutan huruf dan angka pada pelat nomor kendaraan namun terdapat kesalahan dalam identifikasi huruf dan angka pada citra pelat nomor kendaraan, dalam beberapa pengujian model *pytesseract* tidak dapat mendeteksi huruf dan angka pada citra pelat nomor kendaraan.

Tabel 5. Hasil pengujian pelat nomor warna putih

actual license plate	OCR Methods		
	easyocr	kerasocr	pytesseract
B 2807 UID	8	b 2807 uid a	
B 1127 BRD	0	1127 brd	e 1127 brd]
A 1870 YU	18770	1870 yu d	
B 2175 UIB	8 2175	uib 2175 b os27	b 2t9 u1b)
B 2663 PBU	b	pbu 2663 b 68126	
B 2426 TVI	b	tvi 2426 b 21 11	
B 1611 PF	b	pf 1011 b te	

B 2248 POX	b 2248 poxl	pox 2218 b anl
B 1247 IR	b	ir 1211 b 2n
B 1266 WIO	b	wio 166 b cle28 s

Tabel 5 menunjukkan hasil pengujian pada pelat nomor dengan latar putih. Secara keseluruhan hasil pengujian ketiga model OCR memiliki hasil yang serupa dengan hasil pengujian pada pelat nomor dengan latar hitam. Perbedaan dengan pengujian pada pelat nomor dengan latar hitam terlihat pada model *pytesseract* yang lebih sulit melakukan deteksi pada pelat nomor dengan latar putih sehingga banyak pengujian yang tidak menunjukkan hasil. Perbedaan hasil pada ketiga metode OCR dapat dipengaruhi oleh berbagai hal misalnya struktur model dari OCR tersebut dan data yang digunakan dalam melatih model OCR, kualitas dari citra yang di deteksi juga dapat mempengaruhi hasil deteksi dari model OCR, jika terdapat *noise* atau *blur* pada citra maka huruf dan angka pada citra lebih sulit untuk diidentifikasi, hal lain yang dapat mempengaruhi hasil deteksi adalah jenis font yang digunakan pada citra serta posisi huruf dan angka pada citra. Performansi setiap model OCR dapat dilihat melalui akurasi pada tabel 6.

Tabel 6. Akurasi model OCR

LP Background Color	easyocr	kerasocr	pytesseract
Black	37.2%	50.9%	29.8%
White	33.9%	54.0%	9.60%
Total Avg	35.6%	52.5%	19.7%

Pada tabel 6 dapat dilihat bahwa model *easyocr* dan *pytesseract* memiliki akurasi yang lebih baik pada pengujian terhadap pelat nomor dengan latar hitam sementara model *kerasocr* memiliki akurasi yang lebih baik pada pelat nomor kendaraan dengan latar putih. Secara keseluruhan dari total rata-rata model *kerasocr* memiliki hasil yang paling baik dengan nilai akurasi rata-rata sebesar 52.5% dibandingkan dengan model *easyocr* yang memiliki nilai akurasi rata-rata sebesar 35.6% dan model *pytesseract* yang memiliki nilai akurasi rata-rata sebesar 19.7%.

5. Kesimpulan

Berdasarkan percobaan yang telah dilakukan, dapat disimpulkan bahwa metode YOLOv7 mampu mendeteksi pelat nomor kendaraan dengan baik dalam kondisi kurang pencahayaan. Penelitian ini mencapai nilai presisi sebesar 98.1%, nilai recall sebesar 95.5%, dan nilai mAP@0.5 sebesar 99.3%. Untuk meningkatkan performa YOLOv7 dalam mendeteksi pelat nomor dalam kondisi pencahayaan yang kurang baik, dapat dilakukan penggunaan bobot dari YOLOv7 yang telah dilatih sebelumnya, yang juga dikenal sebagai *transfer learning*. Penelitian ini juga menerapkan tiga model OCR yang umum digunakan yaitu *easyocr*, *kerasocr*, dan *pytesseract*. Model *kerasocr* memiliki hasil yang paling baik dibandingkan *easyocr* dan *pytesseract* dengan nilai akurasi rata-rata sebesar 52.5%, sementara model *easyocr* memiliki nilai akurasi rata-rata sebesar 35.6% dan model *pytesseract* memiliki nilai akurasi rata-rata sebesar 19.7%. Hasil identifikasi OCR dapat dipengaruhi oleh beberapa faktor yang dapat berasal dari model OCR dan citra yang diidentifikasi, salah satu cara yang dapat dilakukan untuk meningkatkan performa model OCR yaitu dengan melakukan *preprocessing* terhadap citra yang digunakan sehingga huruf dan angka pada citra dapat diidentifikasi dengan lebih jelas.

Daftar Pustaka

- [1] R. Laroca *et al.*, "A Robust Real-Time Automatic License Plate Recognition Based on the YOLO Detector," *Proc. Int. Jt. Conf. Neural Networks*, vol. 2018-July, 2018, doi: 10.1109/IJCNN.2018.8489629.
- [2] Y. Xiao, A. Jiang, J. Ye, and M. W. Wang, "Making of Night Vision: Object Detection under Low-Illumination," *IEEE Access*, vol. 8, pp. 123075–123086, 2020, doi: 10.1109/ACCESS.2020.3007610.
- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 2016-Decem, pp. 779–788, 2016, doi: 10.1109/CVPR.2016.91.
- [4] B. Widodo, H. A. Armanto, and E. Setyati, "Deteksi Pemakaian Helm Proyek Dengan Metode

- Convolutional Neural Network,” *J. Intell. Syst. Comput.*, vol. 3, no. 1, pp. 23–29, 2021, doi: 10.52985/insyst.v3i1.157.
- [5] H. Wen, F. Dai, and Y. Yuan, “A study of yolo algorithm for target detection,” *Proc. Int. Conf. Artif. Life Robot.*, vol. 2021, pp. 622–625, 2021, doi: 10.5954/icarob.2021.os13-9.
 - [6] C.-Y. Wang, A. Bochkovskiy, and H.-Y. M. Liao, “YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors,” pp. 1–15, 2022, [Online]. Available: <http://arxiv.org/abs/2207.02696>
 - [7] K. P. P. Aung, K. H. Nwe, and A. Yoshitaka, “Automatic License Plate Detection System for Myanmar Vehicle License Plates,” *2019 Int. Conf. Adv. Inf. Technol. ICAIT 2019*, pp. 132–136, 2019, doi: 10.1109/AITC.2019.8921286.
 - [8] J. Shashirangana, H. Padmasiri, D. Meedeniya, and C. Perera, “Automated license plate recognition: A survey on methods and techniques,” *IEEE Access*, vol. 9, pp. 11203–11225, 2021, doi: 10.1109/ACCESS.2020.3047929.
 - [9] L. Zheng and X. He, “Character segmentation for license plate recognition by K-means algorithm,” *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 6979 LNCS, no. PART 2, pp. 444–453, 2011, doi: 10.1007/978-3-642-24088-1_46.
 - [10] S. Bansal, M. Gupta, and A. K. Tyagi, “A Necessary Review on Optical Character Recognition (OCR) System for Vehicular Applications,” *Proc. 2nd Int. Conf. Inven. Res. Comput. Appl. ICIRCA 2020*, pp. 918–922, 2020, doi: 10.1109/ICIRCA48905.2020.9183330.
 - [11] N. Sarika, N. Sirisala, and M. S. Velpuru, “CNN based Optical Character Recognition and Applications,” *Proc. 6th Int. Conf. Inven. Comput. Technol. ICICT 2021*, pp. 666–672, 2021, doi: 10.1109/ICICT50816.2021.9358735.
 - [12] M. Samantaray, A. K. Biswal, D. Singh, D. Samanta, M. Karuppiah, and N. P. Joseph, “Optical Character Recognition (OCR) based Vehicle’s License Plate Recognition System Using Python and OpenCV,” *Proc. 5th Int. Conf. Electron. Commun. Aerosp. Technol. ICECA 2021*, no. January, pp. 849–853, 2021, doi: 10.1109/ICECA52323.2021.9676015.
 - [13] J. Singh and B. Bhushan, “Real Time Indian License Plate Detection using Deep Neural Networks and Optical Character Recognition using LSTM Tesseract,” *Proc. - 2019 Int. Conf. Comput. Commun. Intell. Syst. ICCIS 2019*, vol. 2019-Janua, pp. 347–352, 2019, doi: 10.1109/ICCIS48478.2019.8974469.
 - [14] R. Padilla, S. L. Netto, and E. A. B. Da Silva, “A Survey on Performance Metrics for Object-Detection Algorithms,” *Int. Conf. Syst. Signals, Image Process.*, vol. 2020-July, pp. 237–242, 2020, doi: 10.1109/IWSSIP48289.2020.9145130.
 - [15] B. Kaur and S. Singh, “Object Detection using Deep Learning: A Review,” *ACM Int. Conf. Proceeding Ser.*, pp. 328–334, 2021, doi: 10.1145/3484824.3484889.

Lampiran